

Sizing bổ sung tài nguyên hệ thống Callbot Inbound CSKH nhu cầu 2022

Người trình ký: Cao Thanh Tùng

Đơn vị trình ký: BU Ứng dụng Giải pháp AI - Trung tâm Phân tích dữ liệu - Khối Công nghệ thông tin - TCT VTT - Tổng Công ty Viễn thông Viettel

Danh sách ký duyệt

STT	Người ký	Đơn vị	Thời gian ký	Ý kiến
1	PHẠM NAM HẢI	Trưởng phòng Hệ thống - Phòng Hệ thống - Trung tâm Công nghệ thông tin - Khối Công nghệ thông tin - TCT VTT - Tổng Công ty Viễn thông Viettel	13/12/2024 08:48:55	
2	TRẦN ĐỨC TRUNG	Phó Giám đốc Trung tâm - Trung tâm Phân tích dữ liệu - Khối Công nghệ thông tin - TCT VTT - Tổng Công ty Viễn thông Viettel	12/12/2024 17:29:40	

PHỤ LỤC 02
ĐỊNH CỠ HỆ THỐNG TRỢ LÝ ẢO CALLBOT INBOUND CHĂM SÓC
KHÁCH HÀNG BỔ SUNG NĂM 2022

I. YÊU CẦU BÀI TOÁN

1. Thông tin hệ thống

STT		Nội dung
1	Mô tả hệ thống	Là hệ thống hỗ trợ giải đáp, chăm sóc khách hàng tự động khi khách hàng gọi lên tổng đài chăm sóc khách hàng
2	Đơn vị phát triển	Trung tâm DAC
3	Thời gian phát triển	Hệ thống được xây dựng năm 2021
4	Mục đích định cỡ	Bổ sung tài nguyên năm 2022 mở rộng hệ thống
4	Đầu mối định cỡ	Trung tâm Chăm sóc khách hàng - VTT - đơn vị yêu cầu: Trongtd1 Trung tâm DAC- đơn vị phát triển: Kienttt6 Phòng Hệ thống - đơn vị thẩm định: Haipn
5	Cơ sở định cỡ	Dựa vào hệ thống Callbot Inbound Chăm sóc khách hàng năm 2021. Dựa vào các hệ thống có tính chất tương đồng ở mức module là: + Hệ thống callout Callbot + Hệ thống trợ lý ảo MyViettel + Hệ thống trợ lý ảo (chatbot) mBCCS
6	Nguyên tắc định cỡ	Tính toán tăng trưởng trong vòng 01 năm theo yêu cầu kinh doanh. Đảm bảo khả năng dự phòng: Các thiết bị phần cứng phải đảm bảo hoạt động với cơ chế dự phòng active-active hoặc active-standby. Đảm bảo hiệu suất hoạt động (KPI): Tải CPU không quá 75%, RAM không vượt quá 90% và ổ cứng không vượt quá 80%. Hệ số dự phòng sai số tính toán: 1.1 Chưa định cỡ full tất cả các cuộc gọi lên tổng đài, định cỡ trên số lượng cuộc gọi của các nghiệp vụ xây dựng năm 2021. So sánh tương đương với hệ thống Callout callbot với năng lực gọi tối đa 120000 cuộc gọi 2 chiều/ngày

2. Thông tin đầu vào chi tiết

STT	Đầu vào	Giá trị định cỡ	Hệ thống hiện tại	Ghi chú
1	Tổng số cuộc gọi/ngày	200000	120000	Định cỡ năm 2021, chưa tính full

				300000 cuộc gọi/ngày
2	Số cuộc gọi tối đa trong giờ cao tải ngày bình thường	10000		Định cỡ năm 2021, chưa tính full 300000 cuộc gọi/ngày
3	Số cuộc gọi tối đa trong giờ cao tải ngày cao tải	20000		Định cỡ năm 2021, chưa tính full 300000 cuộc gọi/ngày
4	Độ dài trung bình một cuộc gọi	2.5 phút (150s)		
5	Số giao dịch đồng thời (CCU)	600	400 (2021)	
6	Môi trường triển khai ứng dụng	OS: Centos, DB: Mariadb, Redis, Kafka, ELK stack, WS/APP: Python, Java, React	OS: Centos, DB: Mariadb, Redis WS/APP: Python, Java, React	

Reply Reply All Forward



Tue 12/3/2024 9:03 PM

thuan@viettel.com.vn

Re: confirm đầu vào sizing mở rộng hệ thống Callbot Inbound và Giám sát cuộc gọi CSKH 2022

To kientt6@viettel.com.vn

Cc tungct@viettel.com.vn; linhncv@viettel.com.vn; datnt89@viettel.com.vn; thudth1@viettel.com.vn; trongtd1@viettel.com.vn

Ok em

Thuan - 0983888839/ 0822768768

Vào ngày 3 thg 12, 2024, lúc 20:36, kientt6@viettel.com.vn đã viết:

Dear chị Thuận,
Như chị em mình đã trao đổi, Chị confirm giúp em đầu vào định cỡ tài nguyên mở rộng năm 2023 cho 2 hệ thống Callbot Inbound Chăm sóc khách hàng, Giám sát cuộc gọi Em cảm ơn

Callbot Inbound Chăm sóc khách hàng:

STT	Đầu vào	Giá trị định cỡ (2022)	Hệ thống hiện tại (2021)	Ghi chú
1	Tổng số cuộc gọi/ngày	200000	120000	
2	Số cuộc gọi tối đa trong giờ cao tải ngày bình thường	10000		
3	Số cuộc gọi tối đa trong giờ cao tải ngày cao tải	20000		
4	Số giao dịch đồng thời (CCU)	600	400 (2021)	

Giám sát cuộc gọi CSKH:

STT	Đầu vào	Giá trị định cỡ (2022)	Hệ thống hiện tại	Ghi chú
1	Tổng số cuộc gọi/ngày giữa khách hàng và đội thoại viên	450000(năm 2022)	300000 (năm 2021) 450000 (năm 2022)	
2	Số giao dịch đồng thời	400 (2022)	300 (2021) 400 (2022)	
3	Số người dùng đồng thời của hệ thống (CCU)	400 (2022)	300 (2021) 400 (2022)	
4	Số cuộc gọi tối đa trong giờ cao tải ngày bình thường	20000		
5	Số cuộc gọi tối đa trong giờ cao tải ngày cao tải	40000		


II. GIẢI PHÁP THIẾT KẾ

1. Quan điểm thiết kế

Hệ thống trợ lý ảo Inbound Callbot chăm sóc khách hàng là phần mềm trợ lý ảo hỗ trợ Trung tâm Chăm sóc khách:

- Tiếp nhận cuộc gọi tự động của khách hàng từ tổng đài
- Nhận diện câu nói của khách hàng tự động
- Trả lời tự động khách hàng bằng giọng nói
- Chuyển tư vấn viên kèm nội dung hội thoại khi không trả lời được

2. Mô hình tổng thể



Hình 1: Mô hình hệ thống Callin Callbot

Chức năng của các module:

- Bot Gateway (phone gate way + bot controller) :
 - o Là trung gian giao tiếp voice streaming với tổng đài (IPCC) bao gồm: tiếp nhận luồng voice streaming từ tổng đài để nhận thông tin khách hàng nói, gửi thông tin trả lời của bot dưới dạng voice cho tổng đài để chuyển đến người dùng.
 - o Chuyển cuộc gọi cho tư vấn viên trong trường hợp bot không trả lời được
 - o Là trung gian phối luồng giao tiếp với các module: ASR (Automatic speech recognition: mục đích chuyển voice của khách hàng thành text), text to speech (chuyển nội dung text trả lời khách hàng thành giọng nói),
- ASR (Automatic Speech Recognition):
 - o Nhận diện tiếng người nói (Voice activity detection)
 - o Xử lý nhận diện online streaming chuyển giọng nói (speech) thành text
 - o Nhận diện dấu hiệu kết thúc câu nói của khách hàng.
- TTS (Text to speech):


- Thực hiện chuyển đổi đầu ra của chatbot core dưới dạng text thành giọng nói (file wav)
- Bot core: Xử lý nghiệp vụ lõi của chatbot bao gồm nhận diện intent, entity, xử lý hội thoại, lấy thông tin dữ liệu trả lời từ Business Adapter,...
- Business Adapter: Là trung gian giao tiếp với các hệ thống backend để lấy thông tin đầu vào cho bot trả lời
- Web nghiệp vụ: Xử lý nghiệp vụ web của hệ thống
 - Cấu hình
 - Web tra cứu thông tin, chi tiết cuộc gọi, báo cáo, dashboard
 - Web đánh giá chất lượng cuộc gọi của bot
- Redis: Lưu cache của hệ thống
- Kafka: Hàng đợi trong quá trình xử lý của hệ thống
- ELK Stack:
 - Elasticsearch: lưu trữ dữ liệu text của cuộc gọi, search engine cho hệ thống
 - Lưu trữ, giám sát log tập trung toàn bộ hệ thống
- Database: Cơ sở dữ liệu của hệ thống

Công nghệ sử dụng:

- App:
 - Python, Java: Xây dựng webapps, tiến trình xử lý nghiệp vụ
- Database :
 - Redis, MariaDB.
- Kafka
- Elastic search

III. TÍNH TOÁN CẤU HÌNH PHẦN CỨNG

1. Mô hình vật lý



Mô hình vật lý mô tả thành phần hệ thống cũ và mới cần bổ sung
(Các thành phần bổ sung được khoanh đỏ)

2. Thông tin kết nối:

STT	IP nguồn	Ip đích	Port	Mục đích
1	10.x.x.x (IP cấp bổ sung)	10.60.102.181 10.240.197.50 10.207.59.201	8224, 6869, 9200	Mở kết nối đến hệ thống My Viettel để gọi API tra cứu
2	10.x.x.x (IP cấp bổ sung)	10.240.147.246 10.207.156.201	8001, 8005, 8241, 8291	Mở kết nối đến hệ thống BCCS CC để gọi API tra cứu
3	10.x.x.x (IP cấp bổ sung)	10.240.147.243 10.240.147.246 10.240.147.248	8001, 8003, 8004	Mở kết nối đến hệ thống BCCS CM để gọi API tra cứu
4	10.x.x.x (IP cấp bổ sung)	10.240.147.243	8003	Mở kết nối đến hệ thống Payment để gọi API tra cứu
5	10.x.x.x (IP cấp bổ sung)	10.240.147.247	8009	Mở kết nối đến hệ thống Product Catalog để gọi API tra cứu
6	10.x.x.x (IP cấp bổ sung)	10.240.147.247	8001	Mở kết nối đến hệ thống Product để gọi API tra cứu
7	10.x.x.x (IP cấp bổ sung)	10.60.7.126	9903	Mở kết nối đến hệ thống SPM để gọi API tra cứu
8	10.x.x.x (IP cấp bổ sung)	10.60.129.245	9008	Mở kết nối đến hệ thống GBOC để gọi API tra cứu
9	10.x.x.x (IP cấp bổ sung)	10.240.147.245	8034	Mở kết nối đến hệ thống MNP để gọi API tra cứu
10	10.x.x.x (IP cấp bổ sung)	10.240.147.245	8013	Mở kết nối đến hệ thống Order để gọi API tra cứu
11	10.x.x.x (IP cấp bổ sung)	10.30.130.232 125.235.240.36	465	Mở kết nối đến hệ thống mail viettel

12	10.255.60.6	10.x.x.x (IP cấp bổ sung)	22	Mở kết nối từ server jenkins đến hệ thống Callbot Inbound
13	10.240.147.175- 10.240.147.189 10.240.147.25- 10.240.147.47 10.58.4.80 10.60.96.48 10.60.96.51 10.240.147.15 10.240.147.16 10.240.147.192- 10.240.147.198 10.60.96.53 10.60.96.54	10.x.x.x (IP cấp bổ sung)	8020	Mở kết nối từ hệ thống CC đến hệ thống Callbot Inbound
14	10.60.129.68 10.60.129.69 10.60.130.1 10.60.130.2 10.60.130.3 10.60.130.10 10.60.130.11 10.60.130.12 10.207.161.13- 10.207.161.36 10.254.130.193 10.254.130.194 10.254.130.195	10.x.x.x (IP cấp bổ sung)	8020	Mở kết nối từ hệ thống API Gateway đến hệ thống Callbot Inbound
15	10.60.129.68 10.60.129.69 10.60.130.1 10.60.130.2 10.60.130.3 10.60.130.10 10.60.130.11 10.60.130.12 10.207.161.13- 10.207.161.36 10.254.130.193 10.254.130.194 10.254.130.195	10.x.x.x (IP cấp bổ sung)	8020	Mở kết nối từ hệ thống GBoc đến hệ thống Callbot Inbound
16	10.255.59.180 10.255.59.181 10.255.59.182 10.255.59.183	10.x.x.x (IP cấp bổ sung)	8020	Mở kết nối từ hệ thống Order đến hệ thống Callbot Inbound
17	10.208.70.9 10.208.70.10 192.168.92.13 192.168.92.14 10.40.6.4 10.40.6.5	10.x.x.x (IP cấp bổ sung)	9020	Mở kết nối từ hệ thống IPCC đến hệ thống Callbot Inbound

18	10.208.70.9 10.208.70.10 192.168.92.13 192.168.92.14 10.40.6.4 10.40.6.5	10.x.x.x (IP cấp bổ sung)	8100	Mở kết nối từ hệ thống IPCC, CC đến hệ thống Callbot Inbound
19	10.x.x.x (IP cấp bổ sung)	10.208.70.9 10.208.70.10 192.168.92.13 192.168.92.14 10.40.6.4 10.40.6.5	8287	Mở kết nối đến hệ thống IPCC
20	10.x.x.x (IP cấp bổ sung)	10.240.147.246	8004	Mở kết nối đến hệ thống CM
21	10.x.x.x (IP cấp bổ sung)	10.240.147.245	8013	Mở kết nối đến hệ thống Order
22	10.x.x.x (IP cấp bổ sung)	10.240.147.246	8005	Mở kết nối đến hệ thống CM
23	10.x.x.x (IP cấp bổ sung)	10.240.147.246	8005	Mở kết nối đến hệ thống CM
24	10.207.188.23- 10.207.188.44 10.207.191.9- 10.207.191.12 10.207.188.1- 10.207.188.4 10.207.188.8- 10.207.188.9	10.x.x.x (IP cấp bổ sung)	22, 3306, 4006 8000-8029 8100-8129 8220-8229 9000-9049 9090-9099 9150-9169 9200-9229	Mở kết nối đến hệ thống Giám sát cuộc gọi
25	10.x.x.x (IP cấp bổ sung)	10.255.62.56- 10.255.62.71 10.255.62.29	22, 3306, 4006 8000-8029 8100-8129 8220-8229 9000-9049 9090-9099 9150-9169 9200-9229	Mở kết nối từ hệ thống Giám sát cuộc gọi
26	10.255.62.56- 10.255.62.71 10.255.62.29	10.x.x.x (IP cấp bổ sung)	22, 3306, 4006 8000-8029 8100-8129 8220-8229 9000-9049 9090-9099 9150-9169 9200-9229	Mở kết nối từ hệ thống Giám sát cuộc gọi
27	10.x.x.x (IP cấp bổ sung)	10.254.136.106- 10.254.136.111 10.207.163.16 10.255.56.71 10.255.56.72	22, 3306, 4006 8000-8029 8100-8129 8220-8229 9000-9049 9090-9099 9150-9169 9200-9229	Mở kết nối đến hệ thống Chatbot

28	10.254.136.107 10.254.136.109 10.254.136.110 10.254.136.111 10.207.163.16 10.255.56.71 10.255.56.72	10.x.x.x (IP cấp bổ sung)	22, 3306, 4006 8000-8029 8100-8129 8220-8229 9000-9049 9090-9099 9150-9169 9200-9229	Mở kết từ đến hệ thống Chatbot
29	10.x.x.x (IP cấp bổ sung)	10.254.147.33- 10.254.147.36 10.254.146.144- 10.254.146.17	22, 3306, 4006 8000-8029 8100-8129 8220-8229 9000-9049 9090-9099 9150-9169 9200-9229	Mở kết nối luồng video đến hệ thống Stringee
30	10.254.147.33- 10.254.147.36 10.254.146.144- 10.254.146.17	10.x.x.x (IP cấp bổ sung)	22, 3306, 4006 8000-8029 8100-8129 8220-8229 9000-9049 9090-9099 9150-9169 9200-9229	Mở kết nối luồng video đến hệ thống Stringee
31	10.x.x.x (IP cấp bổ sung)	10.208.133.214- 10.208.133.223 10.208.133.202- 10.208.133.204	22, 3306, 4006 8000-8029 8100-8129 8220-8229 9000-9049 9090-9099 9150-9169 9200-9229	Mở kết nối luồng video đến hệ thống VTS
32	10.208.133.214- 10.208.133.223 10.208.133.202- 10.208.133.204	10.x.x.x (IP cấp bổ sung)	22, 3306, 4006 8000-8029 8100-8129 8220-8229 9000-9049 9090-9099 9150-9169 9200-9229	Mở kết nối luồng video đến hệ thống VTS

3. Định cỡ thiết bị máy chủ

3.1 Định cỡ cụm máy chủ App: Gateway + web

Cấu hình cụm server đang chạy 400 CCU (2021)

Phân hệ	Cấu hình	IP	Số lượng
Gateway + web	CPU = 96 Cint 2017 RAM: 64 GB SSD: 1820 GB Có card HBA	10.207.188.27 10.207.188.28 10.207.188.29 10.207.188.30 10.207.188.31	5

Hệ thống cài đặt các module nhiều chân giống nhau trên nhiều server, các webservice sẽ triển khai LoadBalancer của VTNet để phân tải đều, do đó tải giữa các server trong cụm giống nhau.

LB cấp phát:

3	LoadBalancer	10.207.188.201:9203	http	source ip	900	roundrobin	10.207.188.27:9203 10.207.188.28:9203 10.207.188.29:9203 10.207.188.30:9203 10.207.188.31:9203	Enable	Interval: 5s Timeout: 5s Giáo thức: http port: 9203 URL health check: /get	Mã trả về 200
---	--------------	---------------------	------	-----------	-----	------------	--	--------	--	---------------

Đo tải thực tế trên các server app đang chạy:

Tải đo khi hệ thống chạy 270 CCU:

- Tải RAM:

```
[os_callbot@callbot_gw1 ~]$ free -m
              total        used         free       shared    buff/cache   available
Mem:           64261       32538         14032          6404         17690         18688
Swap:           8191         1145          7046
[os_callbot@callbot_gw1 ~]$
```

- Tải CPU:

Cấu hình CPU:

```
[os_callbot@callbot_gw1 ~]$ lscpu
Architecture:          x86_64
CPU op-mode(s):        32-bit, 64-bit
Byte Order:            Little Endian
CPU(s):                32
On-line CPU(s) list:   0-31
Thread(s) per core:    1
Core(s) per socket:    1
Socket(s):             32
NUMA node(s):          1
Vendor ID:             GenuineIntel
CPU family:            6
Model:                 85
Model name:            Intel Xeon Processor (Skylake, IBRS)
Stepping:              4
CPU MHz:               2992.974
BogoMIPS:              5985.94
Hypervisor vendor:     KVM
Virtualization type:   full
L1d cache:             32K
L1i cache:             32K
L2 cache:              4096K
L3 cache:              16384K
NUMA node0 CPU(s):     0-31
```

```

[os_callbot@callbot_gw1 ~]$ top
top - 11:15:47 up 138 days, 18:24, 2 users, load average: 1.73, 1.74, 1.82
Tasks: 661 total, 1 running, 660 sleeping, 0 stopped, 0 zombie
%Cpu(s): 42.3 us, 1.5 sy, 0.0 ni, 55.3 id, 0.0 wa, 0.0 hi, 0.9 si, 0.0 st
KiB Mem : 65804076 total, 23221852 free, 27444156 used, 15138068 buff/cache
KiB Swap: 8388604 total, 7168160 free, 1220444 used, 25087456 avail Mem

```

Bảng tính toán thông số:

STT	Thông số	Máy chủ Tiến trình	Ghi chú
1	Cint/1CCU	$42.3 \times 96 / 100 / (270/5)$ ~ 0.752	
2	RAM/1CCU	$32538 / (270/5)$ ~ 602.56	
3	Giá trị định cỡ (CCU)	600	
4	Cint cần cho 600 CCU	0.752×600 ~ 451.2	
5	RAM cần cho 600 CCU	602.56×600 ~ 361533	
6	Cint cần sau khi nhân hệ số dự phòng và đảm bảo KPI	$451.2 \times 1.1 / 0.75$ ~ 661.76	KPI 75%
7	RAM cần sau khi nhân hệ số dự phòng và đảm bảo KPI	$361533 \times 1.1 / 0.9$ ~ 441874	KPI 90%
Tổng tài nguyên phục vụ cho 600 CCU : CPU: 661.76 CINT, RAM: 441 GB			

- Tải ổ cứng lưu trữ 60000 cuộc gọi 1 ngày:

```

Filesystem      Size  Used Avail Use% Mounted on
devtmpfs        32G   0    32G   0% /dev
tmpfs            32G   0    32G   0% /dev/shm
tmpfs            32G  3.2G   29G  10% /run
tmpfs            32G   0    32G   0% /sys/fs/cgroup
/dev/vda1        59G   34G   23G  60% /
/dev/mapper/vg--u01-lv--u01 886G 368G 474G 44% /u01
/dev/mapper/vg--u02-lv--u02 788G  9.2G 739G  2% /u02
tmpfs            6.3G   0    6.3G   0% /run/user/1001
tmpfs            6.3G   0    6.3G   0% /run/user/1000

```

STT	Số cuộc gọi 1 ngày	HDD/SSD 1 server
-----	--------------------	------------------

1	60000 cuộc gọi 1 ngày	377 GB
2	80000 cuộc gọi 1 ngày	$(377 * 5 / 60000 * 80000) / 0.8 * 1.1$ ~ 3455 GB

Với 200 CCU bổ sung năm 2022 so với năm 2021 (đang sử dụng 5 server) (lũy kế 2021: 400 CCU, 2022: 600 CCU) thì cần bổ sung tương ứng:

Cint: $(661.76 - (96 * 5)) \sim 182$ Cint 2017

RAM: $(441 - (64 * 5)) \sim 121$ GB RAM

Ổ cứng 3.46 TB để bổ sung 80000 cuộc gọi

Như vậy tài nguyên server cần bổ sung năm 2022 lựa chọn bổ sung như sau

Phân hệ	Cấu hình	Số lượng
Gateway + web	CPU = 96 Cint 2017 RAM: 64 G SSD: 1820 GB Có card HBA	2

3.2 Định cỡ cụm Máy chủ ASR (speech to text) +TTS (text to speech)

Cấu hình cụm server đang chạy 400 CCU (2021)

1	Máy chủ ASR (speech to text) +TTS (text to speech)	CPU = 280 Cint 2017 RAM = 256 GB GPU: 8x GPU RTX 6000 = 24GB SSD = 1500 GB Có card HBA Storage dùng chung giữa các server này và 4 server Chatbot: 18 TB shared	4	10.207.188.1 10.207.188.2 10.207.188.3 10.207.188.4	Vật lý
---	---	--	---	--	--------

Hệ thống cài đặt các module nhiều chân giống nhau trên nhiều server, các webservice sẽ triển khai LoadBalancer của VTNet để phân tải đều, do đó tải giữa các server trong cụm giống nhau.

LB cấp phát:

7	TTS Client	10.207.188.201:8003	http		source ip	900	roundrobin	10.207.188.1:8003 10.207.188.2:8003 10.207.188.3:8003 10.207.188.4:8003 10.207.188.1:8013 10.207.188.2:8013 10.207.188.3:8013 10.207.188.4:8013 10.207.188.1:8023 10.207.188.2:8023 10.207.188.3:8023 10.207.188.4:8023	Interval: 5s Timeout: 5s Enable Giao thức: http port: 8003,8013,8023 URL health check: /textToSpeechApi/get	Mã trả về 200
---	------------	---------------------	------	--	-----------	-----	------------	--	--	---------------

Đo tải thực tế trên các server app đang chạy:

- Tải GPU:

Số card GPU:

```
[os_callbot@hlc7f-vtt01-gpu-1020718801 ~]$ lspci | grep VGA
01:00.1 VGA compatible controller: Matrox Electronics Systems Ltd. MGA G200eH3 (rev 02)
14:00.0 VGA compatible controller: NVIDIA Corporation TU102GL [Quadro RTX 6000/8000] (rev a1)
15:00.0 VGA compatible controller: NVIDIA Corporation TU102GL [Quadro RTX 6000/8000] (rev a1)
39:00.0 VGA compatible controller: NVIDIA Corporation TU102GL [Quadro RTX 6000/8000] (rev a1)
3a:00.0 VGA compatible controller: NVIDIA Corporation TU102GL [Quadro RTX 6000/8000] (rev a1)
88:00.0 VGA compatible controller: NVIDIA Corporation TU102GL [Quadro RTX 6000/8000] (rev a1)
89:00.0 VGA compatible controller: NVIDIA Corporation TU102GL [Quadro RTX 6000/8000] (rev a1)
b1:00.0 VGA compatible controller: NVIDIA Corporation TU102GL [Quadro RTX 6000/8000] (rev a1)
b2:00.0 VGA compatible controller: NVIDIA Corporation TU102GL [Quadro RTX 6000/8000] (rev a1)
[os_callbot@hlc7f-vtt01-gpu-1020718801 ~]$
```

NVIDIA-SMI 460.56				Driver Version: 460.56		CUDA Version: 11.2	
GPU	Name	Persistence-M	Bus-Id	Disp.A	Volatile Uncorr. ECC		
Fan	Temp	Perf	Pwr:Usage/Cap	Memory-Usage	GPU-Util	Compute M.	MIG M.
0	Quadro RTX 6000	On	00000000:15:00.0	Off		Off	
33%	38C	P2	68W / 260W	23603MiB / 24220MiB	46%	Default	N/A

- Tải CPU:


```
[os_callbot@hlc7f-vtt01-gpu-1020718801 ~]$ lscpu
Architecture:          x86_64
CPU op-mode(s):        32-bit, 64-bit
Byte Order:             Little Endian
CPU(s):                 96
On-line CPU(s) list:   0-95
Thread(s) per core:     2
Core(s) per socket:    24
Socket(s):              2
NUMA node(s):          2
Vendor ID:              GenuineIntel
CPU family:             6
Model:                  85
Model name:             Intel(R) Xeon(R) Gold 6248R CPU @ 3.00GHz
Stepping:               7
CPU MHz:                3000.000
BogoMIPS:               6000.00
Virtualization:         VT-x
L1d cache:              32K
L1i cache:              32K
L2 cache:               1024K
L3 cache:               36608K
NUMA node0 CPU(s):     0-23,48-71
NUMA node1 CPU(s):     24-47,72-95
```

```
top - 15:25:54 up 673 days, 15:04, 1 user, load average: 22.60, 10.33, 4.66
Tasks: 1161 total, 36 running, 1115 sleeping, 0 stopped, 10 zombie
%Cpu(s): 40.6 us, 0.7 sy, 0.0 ni, 58.5 id, 0.0 wa, 0.0 hi, 0.2 si, 0.0 st
KiB Mem : 26360305+total, 6789924 free, 21640160+used, 40411528 buff/cache
KiB Swap: 33554428 total, 2538372 free, 31016056 used. 27539156 avail Mem
```

- Tải RAM và Ổ cứng:

```
[os_callbot@hlc7f-vtt01-gpu-1020718801 ~]$ free -m
              total        used        free      shared  buff/cache   available
Mem:           257424         211316          6615        10546        39493        26905
Swap:           32767          30180          2587

[os_callbot@hlc7f-vtt01-gpu-1020718801 ~]$ df -h
Filesystem      Size  Used Avail Use% Mounted on
devtmpfs         126G   0    126G   0% /dev
tmpfs            126G  48K    126G   1% /dev/shm
tmpfs            126G  4.0G    122G   4% /run
tmpfs            126G   0    126G   0% /sys/fs/cgroup
/dev/mapper/centos-root    50G   11G   40G  22% /
/dev/mapper/centos-home    761G  562G  199G  74% /u01
/dev/sda2          506M  187M  320M  37% /boot
/dev/mapper/centos-var     50G   38G   13G  76% /var
/dev/sda1          512M   12M  501M   3% /boot/efi
10.254.165.28:/callbot_gpu01 3.0T  2.7T  338G  90% /data_nas01
10.254.165.28:/callbot_gpu05 3.0T  429G  2.6T  14% /data_nas05
10.254.165.28:/callbot_gpu02 3.0T  2.6T  477G  85% /data_nas02
10.254.165.28:/callbot_gpu04 3.0T  216G  2.8T   8% /data_nas04
10.254.165.28:/callbot_gpu03 3.0T   1.2T  1.9T  39% /data_nas03
10.254.165.28:/callbot_gpu06 3.0T   2.6T  427G  87% /data_nas06
tmpfs             26G   0    26G   0% /run/user/1001
```

Với 200 CCU bổ sung năm 2022 tăng so với năm 2021 (đang sử dụng 4 server 8 Card RTX 6000) (lũy kế 2021: 400 CCU) thì cần bổ sung tương ứng 50% tài nguyên của cụm server này so với năm 2021.

Số card cần bổ sung = $50\% * 8 * 4 = 16$ card A30.

Nên cần tương ứng 16 / 3 ~ 5 server 3x GPU A30

Dung lượng trên mỗi server dùng cài đặt môi trường triển khai cần tương ứng server hiện tại để đáp ứng.

Như vậy tài nguyên server cần bổ sung năm 2022 lựa chọn bổ sung như sau

1	Máy chủ Speech processing	CPU = 280 Cintel 2017 RAM = 256 GB GPU: 3x GPU A30 = 24GB SSD = 1500 GB Có card HBA Storage dùng chung giữa các server này và 4 server GPU hiện tại	5	Vật lý
---	----------------------------------	--	---	--------

3.3 Định cỡ cụm máy chủ Chatbot core

Cấu hình cụm server đang chạy 400 CCU (2021)

Phân hệ	Cấu hình	IP	Số lượng
Máy chủ cho chatbot	CPU = 96 Cintel 2017 RAM: 64 GB SSD = 1800 GB Có card HBA Có shared HDD, SSD với các máy chủ ASR + TTS	10.207.188.23 10.207.188.24 10.207.188.25 10.207.188.26	4

Hệ thống cài đặt các module nhiều chân giống nhau trên nhiều server, các webservice sẽ triển khai LoadBalancer của VTNNet để phân tải đều, do đó tải giữa các server trong cụm giống nhau.

LB cấp phát:

9	ServiceNLP	10.207.188.201:8220	http	source ip	900	roundrobin	10.207.188.23:8220 10.207.188.23:8221 10.207.188.24:8220 10.207.188.24:8221 10.207.188.25:8220 10.207.188.25:8221 10.207.188.26:8220 10.207.188.26:8221	Enable	Interval: 5s Timeout: 5s Giáo thức: http port: 8220,8221 URL health check: /service_nlp/api/get	Mã trả về 200
---	------------	---------------------	------	-----------	-----	------------	--	--------	---	---------------

Đo tải thực tế trên các server app đang chạy:

Tải đo khi hệ thống chạy 340 CCU:

- Tải CPU:


```
[os_callbot@callbot_botcore1 ~]$ lscpu
Architecture:          x86_64
CPU op-mode(s):        32-bit, 64-bit
Byte Order:            Little Endian
CPU(s):                 32
On-line CPU(s) list:   0-31
Thread(s) per core:    1
Core(s) per socket:    1
Socket(s):              32
NUMA node(s):          1
Vendor ID:              GenuineIntel
CPU family:             6
Model:                 85
Model name:             Intel Xeon Processor (Skylake, IBRS)
Stepping:              4
CPU MHz:               2992.968
BogoMIPS:              5985.93
Hypervisor vendor:     KVM
Virtualization type:    full
L1d cache:             32K
L1i cache:             32K
L2 cache:              4096K
L3 cache:              16384K
NUMA node0 CPU(s):     0-31
```

```
Tasks: 382 total,  1 running, 381 sleeping,  0 stopped,  0 zombie
%Cpu(s): 48.2 us,  0.1 sy,  0.0 ni, 51.6 id,  0.0 wa,  0.0 hi,  0.0 si,  0.0 st
KiB Mem : 65804076 total, 3270844 free, 50408612 used, 12124620 buff/cache
KiB Swap: 8388604 total, 6417056 free, 1971548 used. 5596544 avail Mem

  PID USER      PR  NI    VIRT    RES    SHR S  %CPU  %MEM     TIME+ COMMAND
34983 os_call+  20   0   44.4g   17.0g   8464 S   824.3  27.1  54814.29 java
36451 os_call+  20   0   44.5g   16.8g   7912 S   94.4  26.7  24447.59 java
52242 os_call+  20   0 153300    4184    596 S    24.9   0.0   0:03.89 python
52238 os_call+  20   0 153300    4184    604 S    24.6   0.0   0:04.80 python
52231 os_call+  20   0 153300    4176    604 S    24.3   0.0   0:04.03 python
52240 os_call+  20   0 153300    4184    604 S    24.3   0.0   0:04.42 python
```

- Tải RAM:

```
[os_callbot@callbot_botcore1 ~]$ free -m
              total        used        free      shared  buff/cache   available
Mem:           64261        44417         2844         3264        17000        10157
Swap:           8191         1972         6219
```

STT	Thông số	Máy chủ Tiên trình	Ghi chú
1	Cint/1CCU	$54.6 \cdot 96 / 100 / (340 / 4)$ ~ 0.636988235	
2	RAM/1CCU	$44417 / (340 / 4)$ ~ 522.5529412	
3	Giá trị định cỡ (CCU)	600	

4	Cint cần cho 600 CCU	$0.637 * 600$ ~ 382.1929412	
5	RAM cần cho 600 CCU	$522.55 * 600$ ~ 313531.7647	
6	Cint cần sau khi nhân hệ số dự phòng và đảm bảo KPI	$382.19 * 1.1/0.75$ ~ 560.5496471	KPI 75%
7	RAM cần sau khi nhân hệ số dự phòng và đảm bảo KPI	$313531 * 1.1/0.9$ ~ 383205.4902	KPI 90%
Tổng tài nguyên phục vụ cho 600 CCU : CPU: 560 CINT, RAM: 383 GB			

- Tải ổ cứng khi lưu trữ 120000 cuộc gọi 1 ngày:

Filesystem	Size	Used	Avail	Use%	Mounted on
devtmpfs	32G	0	32G	0%	/dev
tmpfs	32G	0	32G	0%	/dev/shm
tmpfs	32G	3.2G	29G	10%	/run
tmpfs	32G	0	32G	0%	/sys/fs/cgroup
/dev/vda1	59G	36G	21G	64%	/
/dev/mapper/vg--u02-lv--u02	788G	529G	219G	71%	/u02
/dev/mapper/vg--u01-lv--u01	886G	439G	403G	53%	/u01
tmpfs	6.3G	0	6.3G	0%	/run/user/1001
tmpfs	6.3G	0	6.3G	0%	/run/user/1000

STT	Số lượng cuộc gọi / ngày	HDD/SSD
1	120000 cuộc gọi / ngày	968 GB
2	80000 cuộc gọi / ngày	$(968 * 4 / 120000 * 80000)/0.8 * 1.1$ $\sim 3.455 \text{ TB}$

Với 200 CCU bổ sung năm 2022 so với năm 2021 (đang sử dụng 4 server) (lũy kế 2021: 400 CCU, 2022: 600 CCU) thì cần bổ sung tương ứng:

Cint: $(560.5 - (96 * 4)) \sim 176.5$ Cint 2017

RAM: $(383 - (64 * 4)) \sim 127$ GB RAM

Ổ cứng 3.455 TB để bổ sung 120000 cuộc gọi / ngày

Như vậy tài nguyên server cần bổ sung năm 2022 lựa chọn bổ sung như sau

Phân hệ	Cấu hình	Số lượng
Máy chủ cho chatbot	CPU = 96 Cint 2017 RAM = 64 GB SSD = 1800 GB Có card HBA	2

	Có shared HDD, SSD với các máy chủ ASR + TTS	
--	--	--

3.4 Định cỡ máy chủ ELK Stack

Cấu hình server thực tế đang chạy 400 CCU (năm 2021)

Phân hệ	Cấu hình	IP	Số lượng
ELK Stack	CPU = 96 Cint 2017 RAM = 64 GB SSD = 3400 GB Có card HBA	10.207.188.42 10.207.188.43 10.207.188.44	3

Với 200 CCU bổ sung năm 2022 so với năm 2021 (lũy kế 2021: 400 CCU, 2022: 600 CCU, 2023: 800 CCU) thì cần bổ sung tương ứng 50% ổ cứng của cụm server này so với năm 2021.

Đo tải thực tế trên các server app đang chạy:

- Tải Ổ cứng tương ứng lưu trữ với 100000 cuộc gọi / ngày

```
os_callbot@callbot_elk1 ~]$ df -h
Filesystem      Size  Used Avail Use% Mounted on
devtmpfs        32G   0    32G   0% /dev
tmpfs           32G   0    32G   0% /dev/shm
tmpfs           32G  3.2G   29G  10% /run
tmpfs           32G   0    32G   0% /sys/fs/cgroup
/dev/vda1       59G   21G   37G  36% /
/dev/mapper/vg--u01-lv--u01 1.6T  583G  913G  39% /u01
/dev/mapper/vg--u02-lv--u02 1.7T 1001G  588G  64% /u02
tmpfs           6.3G   0    6.3G   0% /run/user/1001
tmpfs           6.3G   0    6.3G   0% /run/user/1000
```

STT	Số lượng cuộc gọi / ngày	HDD/SSD
1	100000 cuộc gọi / ngày	1584 GB
2	80000 cuộc gọi / ngày	$(1584 * 3 / 100000 * 80000) / 0.8$ $* 1.1$ $\sim 5227 \text{ TB}$

Vậy tài nguyên cần bổ sung cho module ELK Stack như sau:

Phân hệ	Cấu hình	Số lượng
ELK Stack	SSD/HDD bổ sung: 1,7 TB Trên mỗi server: 10.207.188.42 10.207.188.43	3

	10.207.188.44	
--	---------------	--

3.5 Định cỡ cụm máy chủ Business Adapter

Cấu hình cụm server đang chạy 400 CCU (2021)

Phân hệ	Cấu hình	IP	Số lượng
Business Adapter	CPU = 96 Cint 2017 RAM = 64 GB SSD = 990 GB Có card HBA	10.207.188.32 10.207.188.33 10.207.188.34 10.207.188.35	4

Hệ thống cài đặt các module nhiều chân giống nhau trên nhiều server, các webservice sẽ triển khai LoadBalancer của VTNet để phân tải đều, do đó tải giữa các server trong cụm giống nhau.

LB cập phát:

6	BusinessAdapter	10.207.188.201:8120	http	source ip	900	roundrobin	10.207.188.32:8120 10.207.188.33:8120 10.207.188.34:8120 10.207.188.35:8120 10.207.188.32:8121 10.207.188.33:8121 10.207.188.34:8121 10.207.188.35:8121 10.207.188.32:8122 10.207.188.33:8122 10.207.188.34:8122 10.207.188.35:8122 10.207.188.32:8123 10.207.188.33:8123 10.207.188.34:8123 10.207.188.35:8123	Interval: 5s Timeout: 5s Giao thức: http port: 8120, 8121, 8122, 8123 Enable URL health check: /api/business_adapter/get	Mã trả về 200
---	-----------------	---------------------	------	-----------	-----	------------	--	--	---------------

Đo tải thực tế trên các server app đang chạy:

Tải đo khi hệ thống chạy 240 CCU:

- Tải CPU:

```
top - 09:31:00 up 978 days, 19:09, 2 users, load average: 1.91, 2.05, 1.48
Tasks: 374 total, 33 running, 341 sleeping, 0 stopped, 0 zombie
%Cpu(s): 40.8 us, 0.4 sy, 0.0 ni, 58.8 id, 0.0 wa, 0.0 hi, 0.0 si, 0.0 st
KiB Mem : 65804084 total, 3085356 free, 20507104 used, 42211624 buff/cache
KiB Swap: 8388604 total, 7854624 free, 533980 used, 35594516 avail Mem
```

- Tải RAM và Ổ cứng:

```
los_callbot@callbot_bal ~]$ free -m
              total        used        free      shared  buff/cache   available
Mem:           64261        31068         2969         3181        30223        23522
Swap:           8191          322         7869
```

STT	Thông số	Máy chủ Tiến trình	Ghi chú
1	Cint/1CCU	$40.8 \times 96 / 100 / (240 / 4)$ ~ 0.6528	
2	RAM/1CCU	$31068 / (240 / 4)$ ~ 517.8	

3	Giá trị định cỡ (CCU)	600	
4	Cint cần cho 600 CCU	$0.6528 * 600$ ~ 391.68	
5	RAM cần cho 600 CCU	$517.8 * 600$ ~ 310680	
6	Cint cần sau khi nhân hệ số dự phòng và đảm bảo KPI	$391.68 * 1.1/0.75$ ~ 574.464	KPI 75%
7	RAM cần sau khi nhân hệ số dự phòng và đảm bảo KPI	$310680 * 1.1/0.9$ ~ 379720	KPI 90%
Tổng tài nguyên phục vụ cho 600 CCU : CPU: 574 CINT, RAM: 379 GB			

Tải ổ cứng lưu trữ 75000 cuộc gọi / ngày:

```
[os_callbot@callbot_bal temp_storage_sizing]$ df -h
Filesystem      Size  Used Avail Use% Mounted on
devtmpfs        32G   0    32G   0% /dev
tmpfs            32G   0    32G   0% /dev/shm
tmpfs            32G  3.2G   29G  10% /run
tmpfs            32G   0    32G   0% /sys/fs/cgroup
/dev/vda1        59G  42G   15G  75% /
/dev/mapper/vg--u01-lv--u01 886G  593G  249G  71% /u01
tmpfs            6.3G   0    6.3G   0% /run/user/1001
tmpfs            6.3G   0    6.3G   0% /run/user/1000
```

STT	Số lượng cuộc gọi / ngày	HDD/SSD
1	75000 cuộc gọi / ngày	593 GB
2	80000 cuộc gọi / ngày	$(593 * 4 / 75000 * 80000)/0.8 * 1.1$ = 3.478 TB

Với 200 CCU bổ sung năm 2022 so với năm 2021 (đang sử dụng 4 server) (lũy kế 2021: 400 CCU, 2022: 600 CCU) thì cần bổ sung tương ứng:
Cint: $(574 - (96*4)) \sim 190.5$ Cint 2017
RAM: $(379 - (64*4)) \sim 123$ GB RAM
Ổ cứng 3.478 TB để bổ sung 80000 cuộc gọi bổ sung
Như vậy tài nguyên server cần bổ sung năm 2022 lựa chọn bổ sung như sau:

Phân hệ	Cấu hình	Số lượng
---------	----------	----------

Business Adapter	CPU = 96 Cint 2017 RAM = 64 GB SSD = 990 GB Có card HBA	2
-------------------------	--	---

3.6 Định cỡ cụm máy chủ Database

Cấu hình server thực tế đang chạy với 400 CCU

Phân hệ	Cấu hình	IP	Số lượng
Database Maria DB	CPU = 280 Cint 2017 RAM = 96 GB SSD: 3.8 TB Có card HBA 3.8TB HDD backup	10.207.191.9 10.207.191.10 10.207.191.11	3

Với 200 CCU bổ sung năm 2022 so với năm 2021 (lũy kế 2021: 400 CCU, 2022: 600 CCU) thì cần bổ sung tương ứng 50% ổ cứng của cụm server này so với năm 2021. Tương ứng mỗi server cần bổ sung $3.8 / 2 = 1.9$ TB lưu trữ.

Vậy tài nguyên cần bổ sung cho Database như sau:

Phân hệ	Cấu hình bổ sung	Số lượng
Database Maria DB	SSD bổ sung: 1,9 TB Bổ sung 1,9 TB HDD backup dữ liệu theo quy định trên mỗi server: 10.207.191.9 10.207.191.10 10.207.191.11	3

3.7 Định cỡ băng thông


Bandwidth giao tiếp đến và đi hệ thống khác theo luồng voice, video:

Tính toán theo luồng voice:

- CCU: 200
- Băng thông bit rate cho 1 audio 44100 Hz, 2 channel, dạng wav file, 16bit là:
 $44100 * 16 * 2 = 1411200 \text{ bps} = 1411.2 \text{ kbps}$
- Băng thông cho bổ sung 200 CCU: $200 * 1411.2 * K = 338.688 \text{ Mbps}$ (K dự phòng = 1.2)

Công thức tính:

Audio Bit Rate Calculator	Uncompressed	Compressed
Sample Rate (Hz)	44100	
Word Length (bits)	16	
Channels	2	
Bit Rate (kbps, CBR)	1411.20	1411.20
MB per hour	620.2	620.2



Link chi tiết:

http://www.theaudioarchive.com/TAA_Resources_File_Size.htm

Tính toán thông lượng luồng video nghiệp vụ tích hợp hệ thống khác (IPCC), thiết bị đầu cuối (Holobox, TV, Smartphone)

<https://www.synopi.com/bandwidth-required-for-hd-fhd-4k-video>

Resolutions	Required Bandwidth	Required Bandwidth
	H264	H265
1280×720(HD)	3Mbps	1.5Mbps
1920X1080(FHD)	6Mbps	3Mbps
3840×2160 (UHD)	25Mbps	12Mbps
4096×2160 (4K)	32Mbps	15Mbps

- CCU: 200
- Chuẩn nén H264
- Bảng thông cho bổ sung 200 CCU với định dạng FHD: $200 * 6 * K = 1440 \text{ Mbps}$ (K dự phòng = 1.2)
Do vậy, tổng thông lượng phục vụ bổ sung 200 CCU bao gồm luồng thoại và luồng video: $1440 + 338.688 \sim 1778.688 \text{ Mbps}$
Đề xuất thông lượng cần thiết $\geq 1.78 \text{ Gbps}$

IV. TỔNG HỢP ĐỀ XUẤT

STT	Phân hệ	Cấu hình	Số lượng	Ghi chú
1	Gateway + web	CPU = 96 Cint 2017 RAM: 48 GB SSD: 1820 GB Có card HBA	2	Ảo hóa

2	Máy chủ Speech processing	CPU = 280 Cintel 2017 RAM = 256 GB GPU: 3x GPU A30 = 24GB SSD = 1900 GB Có card HBA Storage dùng chung giữa các server này và 4 server Chatbot: 10 TB shared HDD	5	Vật lý
3	Máy chủ cho chatbot	CPU = 96 Cintel 2017 RAM = 64 GB SSD = 1800 GB Có card HBA Có shared HDD, SDD với các máy chủ ASR + TTS	2	Ảo hóa
4	Máy chủ Business Adapter	CPU = 96 Cintel 2017 RAM = 64 GB SSD = 990 GB Có card HBA	2	Ảo hóa
5	ELK Stack	SSD/HDD bổ sung: 1,7 TB	3	Ảo hóa
6	Database Maria DB	SSD bổ sung: 1,9 TB Bổ sung 1,9 TB HDD backup dữ liệu theo quy định	3	Vật lý/Ảo hóa Bổ sung ổ cứng
7	Băng thông	>= 1.78 Gbps		

TRUNG TÂM PHÂN TÍCH DỮ LIỆU


Trần Đức Trung

PHÒNG HỆ THỐNG


Phạm Nam Hải